

다변량 시계열 예측 성능 향상을 위한 상관성 마스킹

Improving Multivariate Time Series Forecasting via Correlation Masking

김민 · 조오현
Min Kim and Ohyun Jo

충북대학교 컴퓨터과학전공
{kmin010287, ohyunjo}@chungbuk.ac.kr

요약

본 연구에서는 다변량 시계열 데이터 내 변량 간 상관성을 효과적으로 반영하여 예측 성능을 향상시키기 위한 상관성 마스킹 기법을 제안한다. 다변량 시계열에서는 변량 간 상호작용이 예측 성능에 중요한 영향을 미치며, 이를 고려하기 위해 기존에는 변량 연관(Channel Dependent) 및 변량 독립(Channel Independent) 접근 방식이 활용되어 왔다. 그러나 이러한 방식은 변량 간 상관성을 정밀하게 반영하는 데 한계를 가진다. 이에 본 연구에서는 Granger 인과관계(Granger Causality)를 기반으로 채널 간 상관성을 분석하고, 예측에 기여도가 낮은 변량을 식별하여 제로 마스킹(Zero-Masking) 방식으로 제거하는 기법을 제안한다. 이를 통해 예측에 유의미한 정보만을 선택적으로 활용하도록 한다. 제안 기법의 유효성을 검증하기 위해 두 가지 범용 다변량 시계열 벤치마크 데이터셋과 두 가지 시계열 예측 모델을 대상으로 실험을 수행하였다. 실험 결과, 모든 모델과 데이터에 대해서 최대 7.14% 향상된 성능을 보여준다.

키워드 : 시계열, 예측, Granger 상관관계, 마스킹

1. 서론

다변량 시계열 예측은 교통, 에너지, 금융 등 다양한 분야에서 핵심적인 문제로 다루어지며, 다수의 변량 간 상호작용을 효과적으로 반영하는 것이 예측 성능 향상의 중요한 요소이다. 기존 연구는 이러한 상호작용을 고려하기 위해 변량 연관(Channel Dependent) 방식과 변량 독립(Channel Independent) 방식을 중심으로 다양한 모델 구조를 제안한다. 그러나 이러한 접근은 모든 변량을 동일하게 활용하거나 단순 결합 방식에 의존하는 경향이 있어, 실제로 예측에 기여하지 않는 변량까지 함께 학습되어 성능이 저하되는 문제가 존재한다 [1].

이러한 한계를 극복하기 위해 입력 단계에서 변량의 중요도를 선별하고 불필요한 변량을 제거하는 접근이 필요하다. 특히 단순 상관관계가 아닌 예측 관점에서의 인과적 기여도를 반영하는 것이 중요하다. Granger 인과관계는 특정 시계열이 다른 시계열의 미래 값을 예측하는 데 통계적으로 유의미한 정보를 제공하는지를 판단하는 방법으로, 시계열 간 방향성과 시간 지연을 고려한 인과성을 정량적으로 평가한다 [2].

본 연구는 위 인과관계를 기반으로 각 변량의 예측 기여도를 분석하고, 이를 활용해 중요한 변량만을 선택적으로 활용하는 상관성 마스킹 기법을 제안한다. 제안 기법은 변량별 인과성을 정량적으로 평가하여 기여도가 낮은 변량을 제거하고, 유의미한 정보만을 입력으로 유지하도록 설계한다. 이를 통해 불필요한 변량으로 인한 정보 왜곡을 최소화하고, 다변량 시계열 예측에서 보다 효율적이고 안정적인 학습을 가능하게 한다. 또한 본 기법




그림 1. 상관성 마스킹 구조

Fig. 1. Overview of the proposed causality masking

은 모델 구조에 의존하지 않고 다양한 예측 모델에 적용 가능한 전처리 방식으로 구성하며, 인과적 관계를 효과적으로 활용한다는 점에서 의의를 가진다.

2. 본론

2.1 모델 설계

그림 1은 제안 기법의 전체 구조를 보여준다. 제안 기법은 입력 단계에서 각 변량의 예측 기여도를 평가하고, 기여도가 낮은 변량을 제거한 후 예측 모델에 입력하는 전처리 방식으로 구성한다.

먼저, 다변량 시계열 데이터를 $X \in \mathbb{R}^{T \times N}$ 이라 정의하며, T 는 시계열 길이, N 은 변량의 개수를 의미한다. 특정 목표 변량을 v_r , 나머지 변량을 보조 변량 v_n 이라 정의할 때, 각 변량이 미래 값을 예측하는 데 미치는 영향을 평가하기 위해 Granger 인과관계 기반 점수를 적용한다.

Granger 인과관계 기반 점수는 보조 변량 v_n 의 과거 정보가 목표 변량 v_r 의 예측 오차를 유의미하게 감소시키는지를 기반으로 정의된다. 각 변량에 대해 Granger causality score $GC(v_r, v_n)$ 를 계산하고, 이를 통해 변량

별 예측 기여도를 정량화한다.

이후, 계산된 인과성 점수를 기준으로 유지 변량 비율 ϵ 를 설정하여 채널 마스크 m^τ 을 수식 (1)로 정의한다.

$$m^\tau = \begin{cases} 1, & \text{if } \text{rank}(GC(v_\tau, v_n)) \geq \epsilon \times N \\ 0, & \text{otherwise} \end{cases} \quad (1)$$

여기서 $m^\tau=1$ 인 경우 해당 변량은 유지되며, $m^\tau=0$ 인 경우 해당 변량을 제거한다. 이를 통해 예측에 기여하지 않는 변량을 사전에 제거할 수 있다. 즉, 선택된 변량은 기존 값을 유지하고, 제거된 변량을 모든 시점에서 0으로 치환한다. 정의된 마스크를 원본 입력 데이터에 적용하여 최종 입력 X^{mask} 를 수식 (2)와 같이 구성한다.

$$X^{mask} = X \cdot m^\tau \quad (2)$$

이 방식을 통해 모델은 입력 차원의 구조를 유지하면서도 불필요한 변량의 영향을 제거할 수 있다는 장점을 가진다.

제안 기법은 입력 단계에서 변량별 인과성을 분석하여 기여도가 낮은 변량을 제거하고, 유의미한 정보만을 선택적으로 유지함으로써 모델이 보다 중요한 정보에 집중할 수 있도록 설계되었다. 특히 입력 차원의 구조를 유지하면서 불필요한 변량을 효과적으로 제거할 수 있다는 점에서 기존 방법과 차별성을 가진다.

2.2 실험 설계

본 연구는 제안한 상관성 마스크 기법의 회귀 예측 성능을 평가하기 위해, 기법 적용 전·후의 평균제곱오차 (Mean Squared Error, MSE)와 평균절대오차 (Mean Absolute Error, MAE)를 비교하고, 이에 따른 성능 향상률을 분석한다. 두 지표는 값이 작을수록 예측 성능이 우수함을 의미하며, 오차 감소 정도를 기반으로 성능 개선 효과를 정량적으로 평가한다.

실험은 ETTh1과 Traffic의 두 가지 다변량 시계열 데이터셋을 대상으로 수행한다. ETTh1은 7개의 변량으로 구성된 전력 변압기 온도 데이터이며, Traffic은 862개의 변량을 포함하는 고속도로 교통량 데이터이다.

입력 시계열 길이는 96, 예측 길이는 120으로 설정한다. 모든 모델은 동일한 실험 조건에서 학습 및 평가를 수행한다. 실험에는 서로 다른 구조를 가지는 TimesNet과 iTransformer를 사용한다. 기존 모델과 제안 기법을 적용한 모델 간의 성능을 비교하며, 유지 변량 비율 ϵ 은 80%로 설정한다.

2.3 실험 결과

그림 2는 제안하는 상관성 마스크 기법을 적용한 경우와 기존 방식 간의 성능 향상률을 나타낸다. 성능 비교는 오차의 증감률을 기준으로 개선 성능을 계산하였다.

실험 결과, 제안 기법은 두 데이터셋 모두에서 일관된 성능 향상을 보였다. 특히 ETTh1 데이터셋에서 TimesNet과 iTransformer 모두 MSE와 MAE 지표에서 유의미한 개선이 확인되었다. TimesNet의 경우 모든 오차 지표에서 약 5% 이상의 성능 향상을 보였으며, iTransformer 또한 모든 지표에서 성능적 개선이 나타난 것을 확인할 수 있다.

Traffic 데이터셋에서도 제안 기법은 성능이 향상되었다. 다만 ETTh1에 비해 향상된 폭은 상대적으로 작게 나타났으며, 이는 Traffic 데이터가 높은 변량 수를 가지는 고차원 데이터로 구성되어 있어 일부 변량 제거가 전체 성능에 미치는 영향이 제한적이기 때문으로 해석된

다. 그럼에도 불구하고 모든 설정에서 성능 저하 없이 일관된 개선을 보였다는 점에서 제안 기법의 안정성이 확인된다.




그림 2. 상관성 마스크 적용 후 성능 향상률

Fig. 2. Performance improvement after applying correlation masking

또한, 모델 구조에 관계없이 두 가지 상이한 기반 모델을 사용한 시계열 예측 모델에 모두 적용 가능하여 제안하는 상관성 마스크 기법이 특정 모델에 종속되지 않는 일반적인 전처리 방법임을 확인할 수 있다.

3. 결론

본 연구에서는 다변량 시계열 예측에서 불필요한 변량이 성능 저하를 유발하는 문제를 해결하기 위해, Granger 인과관계를 기반으로 변량의 예측 기여도를 정량적으로 평가하고 이를 활용한 상관성 마스크 기법을 제안하였다.

실험 결과, 제안 기법은 ETTh1 및 Traffic 데이터셋에서 일관된 성능 향상을 보였으며, 서로 다른 구조를 가지는 시계열 모두에서 안정적인 개선 효과를 나타냈다. 이는 제안 방법이 특정 모델 구조에 의존하지 않는 일반적인 전처리 방식으로 활용 가능함을 의미한다.

결과적으로, 본 연구는 다변량 시계열 데이터에서 모든 변량이 동일하게 유의미하지 않음을 실험적으로 확인하고, 인과성 기반 변량 선택이 예측 성능 향상에 효과적임을 입증하였다.

참 고 문 헌

- [1] Han, Lu, Han-Jia Ye, and De-Chuan Zhan. "The capacity and robustness trade-off: Revisiting the channel independent strategy for multivariate time series forecasting." *IEEE Transactions on Knowledge and Data Engineering* 36.11 (2024): 7129-7142.
- [2] Granger, Clive WJ. "Investigating causal relations by econometric models and cross-spectral methods." *Econometrica: journal of the Econometric Society* (1969): 424-438.
- [3] Wu, Haixu, et al. "Timesnet: Temporal 2d-variation modeling for general time series analysis." *arXiv preprint arXiv:2210.02186* (2022).
- [4] Liu, Yong, et al. "itransformer: Inverted transformers are effective for time series forecasting." *arXiv preprint arXiv:2310.06625* (2023).